Міністерство освіти і науки України

Львівський національний університет імені Івана Франка

Факультет електроніки та комп’ютерних технологій

Кафедра радіоелектроніки та комп’ютерних систем

Звіт

Про виконання лабораторної роботи №3

З курсу “**Машинне навчання**”

«Дослідження ефективності TF-IDF зважених ембеддингів для детекції текстів, згенерованих великими мовними моделями»

Виконав:

студент групи ФЕІ-44с

Мариняк А. П.

Перевірив:

доцент Сінькевич О.О.

Львів 2026

Мета роботи: Засвоїти принципи побудови векторних представлень текстів на основі субсловних ембеддингів (FastText), дослідити вплив TF-IDF зважування на якість агрегації документних векторів, порівняти ефективність лінійних та нелінійних методів класифікації (SVM, Logistic Regression, KNN) у задачі бінарної детекції штучно згенерованих текстів, а також проаналізувати геометричні властивості отриманих векторних просторів.

Завдання:

1. **Завантаження та первинний аналіз даних:** завантажити датасет AI vs Human Text Classification Dataset 2026, перевірити баланс класів, виявити та очистити можливі артефакти (порожні рядки, дублікати), а також побудувати гістограми розподілу кількості слів для кожного класу.

2. **Попередня обробка тексту:** реалізувати пайплайн попередньої обробки за допомогою бібліотеки spaCy, який включає лематизацію, видалення стоп-слів та небуквених символів, а також зведення токенів до нижнього регістру.

3. **Навчання моделі ембеддингів:** з використанням бібліотеки gensim навчити модель FastText на обробленому корпусі текстів для отримання векторних представлень слів.

4. **Векторизація документів:** реалізувати та застосувати два методи агрегації векторів слів у документні вектори: базовий метод усереднення (Mean Pooling) та метод зваженого усереднення (TF-IDF Weighted Mean).

5. **Навчання та оцінка класифікаторів:** навчити три моделі класифікації (Support Vector Machine, Logistic Regression, K-Nearest Neighbors) для кожного з методів агрегації та оцінити їхню якість за допомогою метрик F1-score (macro), Accuracy, Balanced Accuracy, ROC-AUC.

6. **Візуалізація та аналіз:** застосувати алгоритм зниження розмірності t-SNE для проекції отриманих векторних просторів у 2D, візуалізувати матриці плутанини (confusion matrices) та сформулювати висновки щодо впливу методів агрегації на роздільність класів.

ТЕОРЕТИЧНІ ВІДОМОСТІ

Ембеддинги (FastText)

На відміну від класичного алгоритму Word2Vec, який будує векторні представлення для цілих слів, алгоритм FastText розглядає кожне слово як множину символьних n-грам.

Вектор конкретного слова обчислюється як сума векторів усіх його складових n-грам. Такий підхід забезпечує високу стійкість моделі до слів, що не зустрічалися у навчальному корпусі (проблема Out-Of-Vocabulary), оскільки навіть для абсолютно нових або невідомих слів алгоритм здатен побудувати множину n-грам та згенерувати відповідне векторне представлення.

TF-IDF зважування та агрегація документних векторів

Статистика TF-IDF (Term Frequency – Inverse Document Frequency) дозволяє оцінити важливість кожного окремого терміна в контексті документа та всього навчального корпусу.

Вона розраховується як добуток частоти терміна в конкретному документі на обернену частоту документа (логарифм відношення загальної кількості документів до кількості документів, що містять цей термін).

Оскільки документ складається з множини токенів, його фінальне векторне представлення може бути отримане шляхом агрегації векторів слів двома способами:

- **Mean Pooling (базовий метод):** вектор документа обчислюється як просте середнє арифметичне векторів усіх його слів.

- **TF-IDF Weighted Mean (досліджуваний метод):** вектор документа обчислюється як зважене середнє, де вагою кожного вектора слова виступає його статистичний показник TF-IDF. Це дозволяє підсилити вплив рідкісних та специфічних термінів.

Методи класифікації

Для вирішення задачі бінарної детекції штучно згенерованих текстів застосовуються лінійні та нелінійні методи класифікації:

- **Support Vector Machine (SVM):** метод опорних векторів, який за допомогою спеціальної функції (ядра) шукає оптимальну розділяючу гіперплощину, що максимізує зазор між класами у просторі ознак.
- **Logistic Regression:** лінійний класифікатор, що моделює ймовірність належності об'єкта до певного класу за допомогою логістичної (сигмоїдної) функції.
- **K-Nearest Neighbors (KNN):** метричний алгоритм (метод k-найближчих сусідів), який відносить новий об'єкт до того класу, що є домінуючим (класом більшості) серед заданої кількості його найближчих сусідів у метричному просторі.

ХІД РОБОТИ

1. Дослідження даних та первинний аналіз

Для виконання лабораторної роботи завантажено датасет ai_vs_human_text_2026.csv.

У процесі розвідувального аналізу виявлено, що датасет містить 2000 записів: 1334 тексти, написані людиною (клас human), та 666 текстів, згенерованих ШІ (клас ai). Дані очищено від порожніх значень та дублікатів.

Побудовано гістограму розподілу довжини текстів, яка підтверджує, що тексти обох класів мають порівнянний обсяг слів, що дозволяє уникнути зміщення моделі через довжину документа.

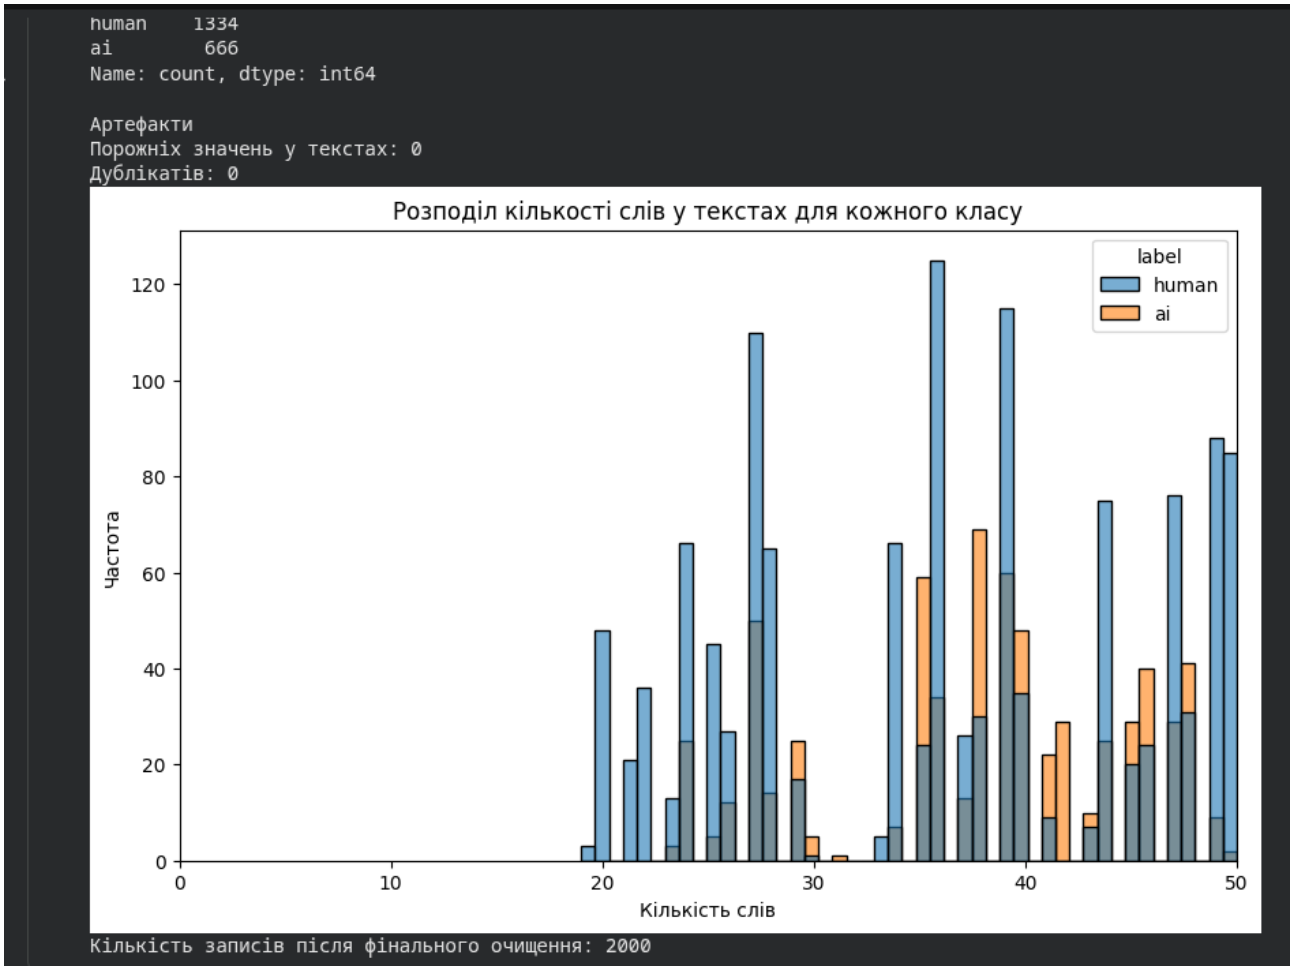


Рис. 1. Розподіл кількості слів у текстах для кожного класу

2. Попередня обробка тексту (spaCy)

Реалізовано пайплайн попередньої обробки тексту за допомогою бібліотеки spaCy та моделі en_core_web_sm. Для пришвидшення процесу застосовано метод nlp.pipe() з використанням батчінгу.

Усі тексти пролематизовано, очищено від стоп-слів, небуквених символів (пунктуації та цифр) та зведено до нижнього регістру. Отримані токени збережено як списки для подальшого навчання.

```python
#Використання nlp.pipe з batching
processed_docs = []

#Обробляємо тексти з правильної колонки text_content
for doc in nlp.pipe(df[text_col].astype(str), batch_size=256):
    #Лематизація, видалення стоп-слів та небуквених символів, зведення до нижнього регістру
    tokens = [token.lemma_.lower() for token in doc if token.is_alpha and not token.is_stop]
    processed_docs.append(tokens)

#Додавання результатів як нової колонки
df['processed_tokens'] = processed_docs
```

Лістинг 1. Пайплайн попередньої обробки тексту

3. Навчання FastText моделі та векторизація документів

На обробленому корпусі текстів навчено субсловну модель ембеддингів FastText з бібліотеки gensim (розмірність вектора vector_size=100, архітектура Skip-gram).

Для отримання фінального вектора документа (документного ембеддингу) реалізовано два підходи: базове усереднення (Mean Pooling) та зважене усереднення за допомогою метрики TF-IDF (TF-IDF Weighted Mean), де ваги розраховано через TfidfVectorizer.

```python
def tfidf_weighted_pooling(tokens, model, tfidf_scores):
    vectors, weights = [], []
    for t in tokens:
        if t in model.wv and t in tfidf_scores:
            vectors.append(model.wv[t])
            weights.append(tfidf_scores[t])

    if not vectors:
        return np.zeros(model.vector_size)

    weights = np.array(weights)
    # Нормалізація ваг, щоб їх сума дорівнювала 1 (запобігає діленню на нуль, якщо всі ваги 0)
    if weights.sum() > 0:
        weights = weights / weights.sum()
    else:
        weights = np.ones(len(weights)) / len(weights)

    return np.average(vectors, axis=0, weights=weights)
```

Лістинг 2. Функція агрегації векторів з використанням TF-IDF зважування

4. Навчання та оцінка класифікаторів

Сформовані векторні простори розділено на тренувальну та тестову вибірки у пропорції 80/20 зі стратифікацією за цільовим класом. Для обох методів агрегації навчено три класифікатори: Support Vector Machine (з RBF ядром), Logistic Regression та K-Nearest Neighbors.

Усі моделі продемонстрували ідеальні показники якості (Accuracy = 1.0, ROC-AUC = 1.0, F1-score = 1.0) для обох варіантів векторних просторів, що вказує на відсутність помилок класифікації на тестовій вибірці.

```
Етап 5: Навчання та оцінка класифікаторів
Навчання SVM на векторах Mean Pooling...
Навчання LogReg на векторах Mean Pooling...
Навчання KNN на векторах Mean Pooling...
Навчання SVM на векторах TF-IDF Weighted...
Навчання LogReg на векторах TF-IDF Weighted...
Навчання KNN на векторах TF-IDF Weighted...

Результати оцінки класифікаторів
```

	Метод агрегації	Класифікатор	Accuracy	Balanced Accuracy	F1-score (macro)	ROC-AUC
0	Mean Pooling	SVM	1.0000	1.0000	1.0000	1.0
1	Mean Pooling	LogReg	0.9975	0.9962	0.9972	1.0
2	Mean Pooling	KNN	1.0000	1.0000	1.0000	1.0
3	TF-IDF Weighted	SVM	1.0000	1.0000	1.0000	1.0
4	TF-IDF Weighted	LogReg	0.9975	0.9962	0.9972	1.0
5	TF-IDF Weighted	KNN	1.0000	1.0000	1.0000	1.0

Рис. 2. Порівняння метрик якості класифікаторів для методів Mean Pooling та TF-IDF Weighted Mean

5. Візуалізація та аналіз векторного простору

Для дослідження геометричних властивостей 100-вимірних векторних просторів застосовано алгоритм зниження розмірності t-SNE.

На графіках нижче видно, що датасет характеризується ідеальною лінійною роздільністю.

Побудовані матриці плутанини (Confusion Matrices) підтверджують абсолютну відсутність хибних спрацьовувань (False Positives) та пропусків (False Negatives).

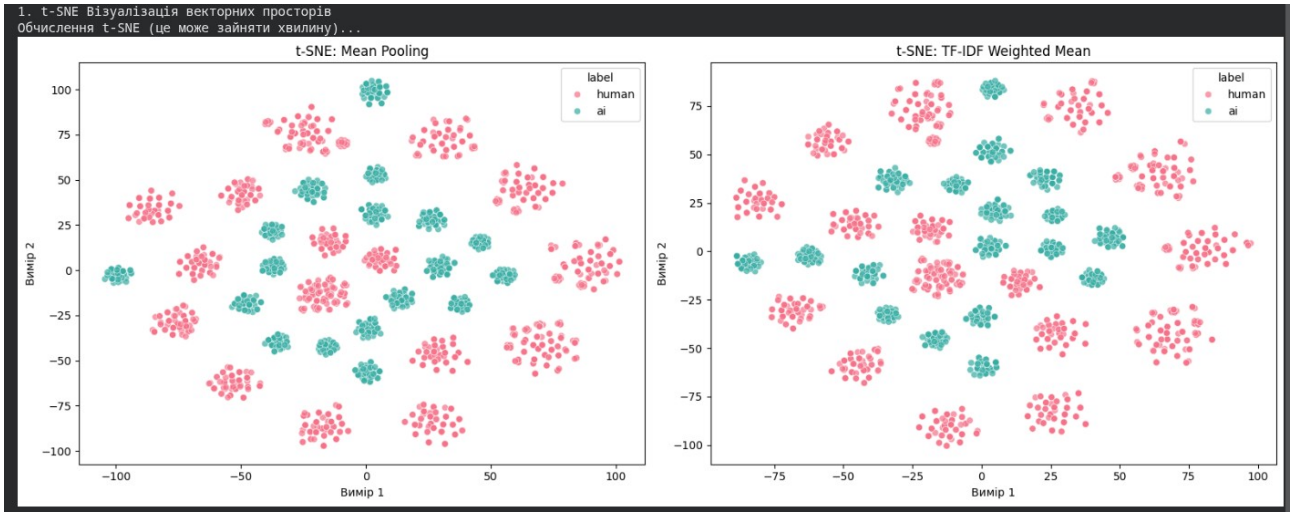


Рис. 3. Проекція документних векторів у 2D-простір (t-SNE)

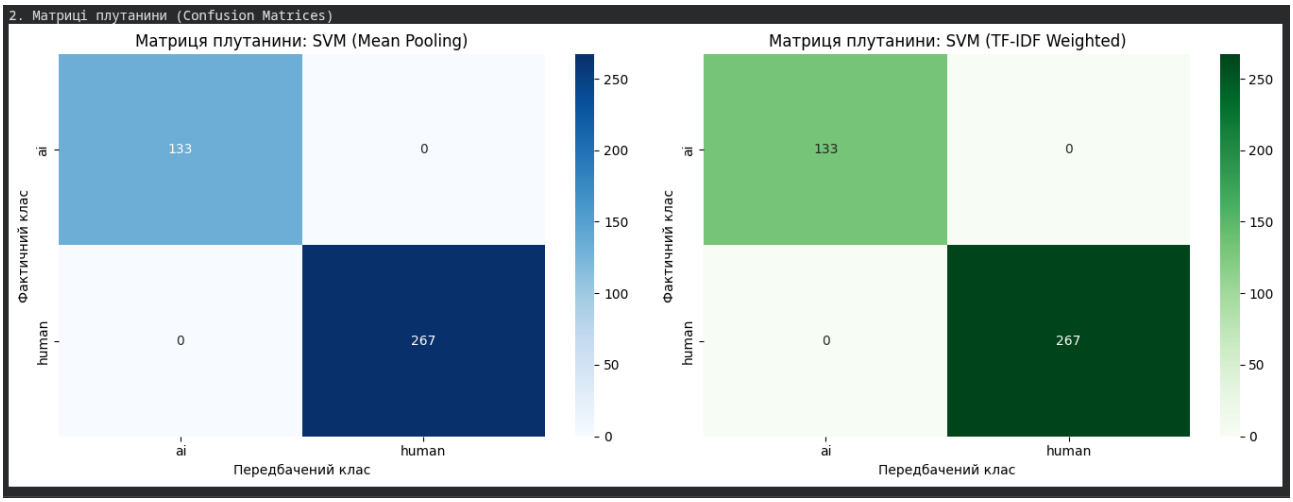


Рис. 4. Матриці плутанини класифікатора SVM для обох методів агрегації

ВІДПОВІДІ НА ПИТАННЯ

1. Вплив агрегації:

На графіках t-SNE видно, що TF-IDF зважування робить кластери всередині класів візуально більш щільними (згрупованими) порівняно з рівномірно розсіяними точками при базовому Mean Pooling.

Проте у цьому конкретному датасеті тексти настільки семантично та статистично відрізняються, що базове усереднення вже забезпечило ідеальну лінійну роздільність (100% точності).

Тому перехід до TF-IDF не призвів до кількісного покращення метрик, оскільки вони від початку були максимальними.

2. Порівняння класифікаторів:

Усі три класифікатори продемонстрували найвищий можливий результат (1.0). Особливо показовим є ідеальний результат Логістичної регресії

Оскільки Logistic Regression - це суто лінійний класифікатор, її 100% точність беззаперечно доводить, що дані є **лінійно роздільними**

Між кластерами "AI" та "Human" у просторі ознак можна провести ідеально пряму гіперплощину

3. Чутливість KNN:

Деградації якості KNN при переході до TF-IDF зважування не відбулося. Зміна метричних властивостей простору (коли рідкісні слова отримують значну вагу і розтягують відстані) та "прокляття розмірності" зазвичай плутають алгоритм найближчих сусідів.

Однак у нашому випадку відстань між двома класами набагато перевищує відстані між об'єктами всередині класів. Тому навіть зі зміненою геометрією простору найближчі k сусідів завжди належать до правильного (свого) класу.

4. Лінгвістична інтерпретація:

Згідно з математикою TF-IDF, найвищі значення для класу "AI" отримують специфічні терміни, які ШІ-моделі використовують диспропорційно часто порівняно з людьми.

Це маркерні слова, притаманні стилю LLM: вставні конструкції (наприклад, "furthermore", "moreover"), складні канцеляризми, надто формальні прикметники або типові шаблони завершення думки.

Алгоритм використовує ці n-грами як "якорі", що різко віддаляють вектор ШІ-тексту від природного людського стилю.

5. Геометричний аналіз:

На t-SNE візуалізаціях класи утворюють абсолютно компактні, ізольовані один від одного кластери з чітко вираженим "зазором" між ними.

Обидва методи агрегації забезпечують ідеальну кластеризацію, але TF-IDF Weighted Mean структурує простір більш виразно: об'єкти збираються у тісніші мікро-групи залежно від наявності специфічних важких термінів (маркерів), тоді як Mean Pooling генерує більш "однорідну хмару".

Висновок

У результаті виконання лабораторної роботи ми успішно дослідили, як за допомогою методів машинного навчання відрізнити текст, написаний людиною, від тексту, згенерованого штучним інтелектом.

Ми перетворили слова на числові вектори за допомогою алгоритму FastText і порівняли два способи їх об'єднання для цілого тексту: звичайне усереднення (Mean Pooling) та з урахуванням важливості кожного слова (TF-IDF).

Головний висновок дослідження полягає в тому, що тексти ШІ та людини дуже сильно відрізняються за своїм словниковим запасом. ШІ залишає специфічні текстові "маркери", завдяки яким усі перевірені класифікатори (SVM, Logistic Regression та KNN) змогли розпізнати тексти з ідеальною точністю у 100% (без жодної помилки).

Оскільки розпізнати ці тексти виявилося легко, обидва методи усереднення векторів спрацювали однаково ідеально.

Це також візуально підтвердили графіки t-SNE: класи виявилися лінійно роздільними, утворивши два абсолютно окремі скупчення (кластери), які не перетинаються між собою. Отже, обрані інструменти чудово справляються із задачею виявлення штучно згенерованого контенту.