

Міністерство освіти і науки України

Львівський національний університет імені Івана Франка

Факультет електроніки та комп'ютерних технологій

Кафедра радіоелектроніки та комп'ютерних систем

Звіт

Про виконання лабораторної роботи №2

3 курсу “Машинне навчання”

«Логістична регресія та федеративне навчання»

Виконав:

студент групи ФЕІ-44с

Мариняк А. П.

Перевірив:

доцент Сінькевич О.О.

Львів 2026

Мета роботи: Зрозуміти архітектуру багатокласової логістичної регресії та навчитися самостійно реалізовувати модель засобами бібліотеки NumPy; зрозуміти принципи федеративного навчання, правильно розподілити дані між клієнтами та сервером, реалізувати агрегацію ваг та проаналізувати базові ефекти розподіленого навчання.

Завдання:

1. **Дослідження даних та попередня обробка:** провести розвідувальний аналіз (EDA), виконати відбір ознак, розбити вибірку на Global Test, Global Validation та FL Train Pool, здійснити кодування категоріальних змінних та масштабування числових ознак без допущення витоку даних (Data Leakage).
2. **Реалізація моделі:** розробити клас багатокласової логістичної регресії з використанням матричних операцій, функції softmax, міні-батчового градієнтного спуску та функції втрат (крос-ентропії) із Ridge-регуляризацією.
3. **Централізоване навчання:** навчити базову еталонну модель на всьому масиві тренувальних даних та оцінити її якість на Global Test за допомогою відповідних метрик.
4. **Розподіл даних:** розподілити тренувальний пул даних між заданою кількістю клієнтів за двома сценаріями: рівномірним (IID-розподіл) та неоднорідним (Non-IID розподіл за допомогою розподілу Діріхле).
5. **Симуляція федеративного навчання:** реалізувати алгоритм FedAvg, де сервер агрегує параметри локальних моделей клієнтів як зважене середнє.
6. **Дослідження ефектів:** провести експерименти для оцінки впливу неоднорідності даних (Non-IID) та кількості локальних епох на якість глобальної моделі, а також дослідити ефект клієнтського дрейфу (client drift).

ТЕОРЕТИЧНІ ВІДОМОСТІ

Багатокласова логістична регресія та оптимізація

Логістична регресія є лінійною моделлю, яка у випадку багатокласової класифікації використовує функцію softmax для отримання ймовірностей класів. Softmax перетворює лінійну частину моделі таким чином, що сума ймовірностей для кожного прикладу дорівнює одиниці

Оптимізація параметрів моделі здійснюється шляхом мінімізації функції втрат - крос-ентропії. Для боротьби з перенавчанням застосовується Ridge-регуляризація, яка додає до функції втрат штраф за величину ваг (L2-норма), при цьому параметр зміщення (bias) зазвичай не регуляризується. Для ефективного навчання моделі застосовується міні-батчевий градієнтний спуск із використанням векторизації та матричних операцій

Попередня обробка та Data Leakage

При підготовці даних критично важливо уникнути явища Data Leakage (витоку даних) - ситуації, коли параметри перетворень (наприклад, масштабування) обчислюються до розбиття вибірки на тренувальну, валідаційну та тестову

Правильний підхід полягає в тому, що параметри масштабування обчислюються виключно на тренувальних даних, і лише після цього застосовуються до валідаційної та тестової множин

Федеративне навчання та архітектура системи

Федеративне навчання - це парадигма розподіленого навчання, в якій беруть участь два типи учасників: центральний сервер (агрегатор) та клієнти

Головний принцип полягає в тому, що сервер НЕ має доступу до сирих даних клієнтів або їхніх локальних тренувальних вибірок

Сервер координує навчання, розсилає глобальну модель, отримує від клієнтів оновлені параметри (ваги) та агрегує їх

Агрегація ваг (FedAvg) та розподіл даних

Агрегація параметрів на сервері за алгоритмом FedAvg виконується як зважене середнє параметрів локальних моделей: клієнти з більшою кількістю тренувальних прикладів мають більший вплив на формування нової глобальної моделі. Дані на клієнтах можуть бути розподілені по-різному:

- **IID-розподіл:** кожен клієнт отримує приблизно однакову кількість прикладів, а пропорції класів збережені та відповідають глобальному розподілу. У цьому сценарії федеративне навчання зазвичай працює стабільно
- **Non-IID розподіл:** моделює неоднорідні дані, де пропорції класів генеруються, наприклад, за допомогою розподілу Діріхле. При високій неоднорідності певні класи у деяких клієнтів можуть бути майже відсутні

Клієнтський дрейф (Client Drift)

Навчання на неоднорідних (Non-IID) даних пов'язане з ризиком погіршення глобальної моделі. Якщо кількість локальних епох занадто велика, виникає явище клієнтського дрейфу - надмірне відхилення ваг локальних моделей від напрямку оптимізації глобальної моделі, оскільки кожна локальна модель починає надто сильно підлаштовуватися виключно під свої специфічні дані

ХІД РОБОТИ

1. Дослідження даних та попередня обробка

Обрав рекомендований датасет Dry Bean Dataset, оскільки він має достатній обсяг числових ознак та 7 класів, що підходить для симуляції федеративного навчання. Пропущених значень не виявлено. Для перевірки мультиколінеарності побудовано матрицю кореляцій




Рис. 1. Матриця кореляцій числових ознак

- Коефіцієнти кореляції між ознаками датасету.
- Група ознак (Area, Perimeter тощо) має кореляцію близьку до 1.
- Це геометричні параметри, що лінійно залежать один від одного.
- Сильно корельовані ознаки видалено для уникнення нестабільності моделі, залишено лише базову Area.

Цільову змінну закодовано через One-Hot Encoding. Дані стратифіковано на Global Test (15%), Global Validation (15%) та FL Train Pool (70%).

```

scaler = StandardScaler()
X_fl_train_scaled = scaler.fit_transform(X_fl_train)

#Застосовую вже навчений скалер (transform) до валідації та тесту
X_global_val_scaled = scaler.transform(X_global_val)
X_global_test_scaled = scaler.transform(X_global_test)

print("\nДані успішно масштабовано без витoku (Data Leakage)")

** Кількість ознак після видалення сильно корельованих: 12

Розміри вибірок:
FL Train Pool: X=(9527, 12), Y=(9527, 7)
Global Validation: X=(2042, 12), Y=(2042, 7)
Global Test: X=(2042, 12), Y=(2042, 7)

```

Лістинг 1. Масштабування без Data Leakage

2. Реалізація логістичної регресії

За допомогою numpy я створив клас MultinomialLogisticRegression із функцією softmax, крос-ентропією з Ridge-регуляризацією та міні-батчевим градієнтним спуском

```
def loss(self, X, Y):
    m = X.shape[0]
    P = self.predict_proba(X)
    #Додаємо epsilon (1e-15), щоб уникнути log(0)
    cross_entropy = - (1/m) * np.sum(Y * np.log(P + 1e-15))
    #Додаємо Ridge (L2) регуляризацію (штраф тільки для матриці W)
    ridge_penalty = (self.lambda_reg / 2) * np.sum(np.square(self.W))
    return cross_entropy + ridge_penalty

def compute_gradients(self, X, Y, P):
    m = X.shape[0]
    #Гرادієнт по вагах W: (X^T * (P - Y)) / m + lambda * W
    dW = (1/m) * np.dot(X.T, (P - Y)) + self.lambda_reg * self.W
    #Градiєнт по зсуву b: сума по стовпцях (P - Y) / m
    db = (1/m) * np.sum(P - Y, axis=0, keepdims=True)
    return dW, db
```

Лістинг 2. Обчислення градієнтів та функції втрат

3. Центральна навчана базова модель

Для створення базової лінії я навчив модель на всьому масиві FL Train Pool




Рис. 2. Навчання централізованої моделі

- Зміна Loss та Accuracy протягом 150 епох
- Стрімке падіння Loss та стабілізація Accuracy на рівні ~92%
- Модель має доступ до всіх репрезентативних даних одночасно
- Модель слугує еталоном якості для федеративного навчання




Рис. 3. Матриця помилок (Global Test)

- Якість розпізнавання кожного з 7 класів
- Основна маса значень на головній діагоналі
- Модель успішно виділила закономірності ознак

4. Розподіл даних

Розподілив FL Train Pool між 10 клієнтами двома способами: IID (рівномірно) та Non-IID (через розподіл Діріхле, $\alpha=0.3$)

```

for c in range(num_classes):
    idx = class_indices[c]
    np.random.shuffle(idx)

    #Пропорції з розподілу Діріхле для поточного класу
    proportions = np.random.dirichlet(np.repeat(alpha, num_clients))

    # Масштабував пропорції до кількості прикладів цього класу
    splits = np.round(proportions * len(idx)).astype(int)

    #Коригував можливі помилки округлення, щоб сума збігалася з кількістю елементів
    splits[-1] = len(idx) - np.sum(splits[:-1])

```

Лістинг 3. Розподіл Діріхле (Non-IID)




Рис. 4. Візуалізація розподілу класів


- Класовий склад даних для кожного з 10 клієнтів
- IID - ідеально рівний розподіл. Non-IID - сильний дисбаланс, домінування 1-2 класів у клієнтів.
- Розподіл Діріхле моделює реальну специфічність локальних даних користувачів.

Етап 5-6. Симуляція федеративного навчання


Реалізував алгоритм FedAvg, де сервер агрегує локальні ваги клієнтів як зважене середнє.

```
weight = len(X_clients[k]) / total_samples
global_W_new += local_model.W * weight
global_b_new += local_model.b * weight
```

Лістинг 4. Агрегація ваг FedAvg



- Залежність Ассигасу глобальної моделі від кількості раундів.
- Модель на IID-даних сходиться швидко. На Non-IID якість суттєво нижча.
- Локальні моделі оптимізуються під наявні в них класи, що дає суперечливі оновлення при агрегації.



- Метрики глобальної моделі при локальних епохах E=1, 5, 10
- При E=10 якість падає порівняно з E=1
- Явище client drift. За 10 епох локальні моделі критично відхиляються від глобального оптимуму.
- На неоднорідних даних треба зменшувати кількість локальних епох (E=1) і частіше комунікувати з сервером.

Фінальне порівняння моделей на Global Test						
	Тип моделі	Accuracy	Macro-F1	Balanced Accuracy	Log-Loss	
0	Локальна (Тільки дані Клієнта 0)	0.1606	0.0565	0.1602	2.6915	
1	Глобальна (Федеративна IID)	0.9143	0.9250	0.9247	0.4070	
2	Централізована (Всі дані)	0.9163	0.9262	0.9249	0.3488	

Централізована модель - найточніша (~91.6%). Локальна на Non-IID даних не узагальнює (~16%)

Глобальна IID-модель (~91.4%) практично наздогнала еталонну, при цьому зберігши конфіденційність локальних даних клієнтів

Висновок

У результаті виконання лабораторної роботи було досліджено архітектуру багатокласової логістичної регресії та реалізовано її математичний апарат за допомогою матричних операцій numpy

Під час підготовки даних на основі датасету Dry Bean було застосовано правильну схему розбиття на множини та коректне масштабування ознак, що дозволило повністю уникнути витoku даних (Data Leakage)

Централізована базова модель, оптимізована за допомогою міні-батчевого градієнтного спуску для функції крос-ентропії з Ridge-регуляризацією, показала високу точність та стала еталоном для подальших порівнянь

Симуляція розподіленого навчання за алгоритмом FedAvg довела, що ефективність глобальної моделі критично залежить від характеру розподілу локальних даних клієнтів

На рівномірних IID-даних федеративна модель працює стабільно і за метриками якості практично не поступається централізованій, успішно виконуючи завдання зі збереження конфіденційності користувачів. Експерименти на неоднорідних (Non-IID) вибірках, згенерованих через розподіл Діріхле, підтвердили суттєве падіння якості загальної моделі

Аналіз впливу кількості локальних епох наочно продемонстрував явище клієнтського дрейфу (client drift): чим довше локальні моделі навчаються на своїх специфічних нерепрезентативних даних, тим сильніше їхні ваги відхиляються від напрямку глобального оптимуму, що руйнує процес усереднення на сервері

Відповіді на теоретичні питання

1. Чому для багатокласової класифікації використовують softmax?

Функція softmax використовується для того, щоб перетворити сирі лінійні виходи моделі (Z) у розподіл імовірностей (P)

Вона гарантує, що всі отримані значення будуть додатними, а сума ймовірностей для кожного прикладу дорівнюватиме одиниці, що дозволяє легко визначити найімовірніший клас

2. Чому крос-ентропія є природною функцією втрат для логістичної регресії?

Крос-ентропія математично випливає з принципу максимальної правдоподібності (Maximum Likelihood Estimation). Вона логарифмічно штрафує модель за невпевнені або неправильні прогнози: чим ближча передбачена ймовірність правильного класу до нуля, тим більшим буде значення втрат

3. Чим відрізняється Ridge-регуляризація від Lasso-регуляризації?

Ridge-регуляризація (L_2) додає до функції втрат штраф у вигляді суми квадратів ваг, що змушує ваги рівномірно зменшуватися, але не дорівнювати нулю. Lasso-регуляризація (L_1) використовує суму модулів ваг, що може повністю занулювати окремі коефіцієнти, виконуючи таким чином вбудований відбір ознак

4. Чому параметр зміщення b зазвичай не регуляризують?

Параметр зміщення (b) відповідає лише за зсув розділяючої гіперплощини відносно початку координат, а не за її нахил чи ступінь впливу окремих ознак. Його велике значення не призводить до підвищеної складності моделі або "перенавчання", тому додавати його до штрафу немає сенсу

5. Що таке Data Leakage?

Витік даних (Data Leakage) - це методична помилка, при якій інформація з тестової або валідаційної вибірки випадково потрапляє в процес навчання моделі. Наприклад, якщо виконати масштабування ознак на всьому датасеті ще до його розбиття на частини

6. Чому тестову вибірку не можна використовувати для підбору гіперпараметрів?

Тестова вибірка (Global Test) призначена виключно для фінальної та об'єктивної оцінки якості вже навченої моделі на абсолютно нових даних. Якщо оптимізувати гіперпараметри на основі результатів тесту, модель "підлаштується" під цю конкретну вибірку, і оцінка її реальної здатності до узагальнення стане хибною

7. Чому параметри масштабування потрібно навчати лише на тренувальних даних?

Щоб уникнути витіку даних (Data Leakage). Статистики (середнє значення та дисперсія) повинні обчислюватися виключно на тренувальній множині ('FL Train Pool'), а до валідаційної та тестової множин мають лише застосовуватися ці вже обчислені параметри

8. Що таке федеративне навчання і які його основні переваги?

Федеративне навчання - це розподілений підхід до машинного навчання, коли локальні моделі навчаються безпосередньо на пристроях (клієнтах), а центральний сервер агрегує лише їхні параметри (ваги). Основна перевага - збереження конфіденційності користувацьких даних, оскільки вони не залишають локальні пристрої

9. Чому сервер не повинен отримувати сирі дані клієнтів?

Для забезпечення приватності та конфіденційності користувачів. Передача сирих даних на сервер суперечить самій концепції федеративного навчання, мета якого - захист локальної інформації учасників

10. Чому агрегація ваг за методом FedAvg використовує зважування за кількістю прикладів?

Тому що клієнти з більшим обсягом даних мають більш репрезентативні локальні вибірки. Їхні оновлення параметрів (градієнти) є точнішими та надійнішими, тому вони повинні мати пропорційно більший вплив на формування нової глобальної моделі

11. Що станеться, якщо агрегувати параметри клієнтів без зважування?

Клієнт із 10 прикладами отримає такий самий вплив на глобальну модель, як і клієнт із 10 000 прикладів. Це призведе до зміщення глобальної моделі в бік шуму та специфічних особливостей нерепрезентативних даних малих клієнтів

12. Що таке Non-IID дані?

Це неоднорідні дані (Non-Independent and Identically Distributed), у яких розподіл класів або ознак у кожного окремого клієнта суттєво відрізняється від загального (глобального) розподілу популяції

13. Чому федеративне навчання може погіршуватися на Non-IID даних?

Через те, що локальні моделі клієнтів оптимізуються лише під ту специфічну підмножину класів, яка є в їхньому розпорядженні, повністю ігноруючи інші. Під час агрегації сервер отримує суперечливі оновлення ваг, що призводить до падіння якості глобальної моделі

14. Що таке клієнтський дрейф (client drift)?

Клієнтський дрейф - це надмірне відхилення параметрів локальних моделей від напрямку глобального оптимуму. Він виникає під час локального навчання на Non-IID даних, коли модель занадто "захоплюється" оптимізацією під свій локальний перекосяк у даних

15. Як кількість локальних епох впливає на глобальну модель?

На неоднорідних (Non-IID) сценаріях велика кількість локальних епох (наприклад, $E=10$) значно посилює ефект клієнтського дрейфу, що різко погіршує якість глобальної моделі після агрегації

16. Чи може глобальна модель бути гіршою за централізовану модель?

Чому?

Так, може. Централізована модель має одночасний доступ до всього масиву тренувальних даних, що дозволяє градієнтному спуску стабільно знаходити глобальний мінімум. Глобальна модель у федеративному навчанні страждає від втрати інформації під час усереднення ваг та клієнтського дрейфу (особливо на Non-IID даних)

17. Які метрики краще використовувати для багатокласової класифікації з можливим дисбалансом класів?

Замість звичайної точності (Accuracy), яка може бути оманливою при домінуванні одного класу, краще використовувати balanced accuracy (усереднена точність по кожному класу незалежно від його обсягу) або macro-F1 (середнє гармонійне між точністю та повнотою, розраховане для кожного класу окремо)